SOLUCIÓN DE INTELIGENCIA DE NEGOCIOS END-TO-END PARA EL MONITOREO Y ANÁLISIS DE LA EFICIENCIA OPERATIVA (OEE) Y PAROS EN LÍNEAS DE ENVASADO

Arquitectura Dimensional, ETL en Python, Monitoreo en Tiempo Real (Grafana) y Tablero Analítico Gerencial (Power BI)

Estudiantes:	Eduardo Deossa Bohórquez & Tomás Restrepo
Asignatura:	Inteligencia de Negocios (Taller 5)
Fecha de Entrega:	6 de Noviembre de 2026
Repositorio GitHub:	https://github.com/EduardoDeossa/BI_Envasado_Docker_PowerBI_Grafana
Nombre de Archivo:	BI_ProyectoFinal_Deossa_Restrepo.docx / .pdf

1. CONTEXTO, DIAGNÓSTICO Y PREGUNTAS DE NEGOCIO

1.1. Identificación de Usuarios y Preguntas de Negocio

La empresa fabricante de vinilos y témperas opera cuatro líneas de envasado automáticas/semiautomáticas (Vinilos_1 a Vinilos_4). Para transformar la recolección manual de datos en una toma de decisiones informada, se definieron tres audiencias estratégicas con necesidades analíticas diferenciadas:

- **1. Alta Dirección / Gerencia de Planta:** Enfoque estratégico, tendencias mensuales, comparativa global de líneas y retorno financiero.
- **2. Jefatura de Mantenimiento e Ingeniería:** Enfoque táctico, causa raíz de paros, tiempos entre fallas (MTBF), reparación (MTTR) y confiabilidad.
- **3. Supervisores de Planta y Operadores de Línea:** Enfoque operativo, alertas en tiempo real, estado instantáneo de máquina y filtrado por turno.

Preguntas de Negocio por Audiencia y su Ubicación en la Solución:

- ¿Cuál es el OEE global consolidado de la planta mes a mes y cómo se compara con el mes anterior? (Visto en Power BI - Página 1: OEE Gerencial)
- ¿Qué línea de envasado presenta la mayor pérdida de productividad y cuál componente (Disponibilidad, Rendimiento o Calidad) es el cuello de botella? (Visto en Power BI - Página 1)
- ¿Cuál es el costo estimado por horas de paro no planificadas según la línea y el turno? (Visto en Power BI - Página 2: Análisis de Paros)
- ¿Cuáles son los subcódigos de paro mecánicos y eléctricos que generan el 80% del tiempo de inactividad (Análisis de Pareto)? (Visto en Power BI - Página 2)
- ¿Cuál es el Tiempo Medio Entre Fallas (MTBF) y el Tiempo Medio de Reparación (MTTR) de cada máquina? (Visto en Power BI - Página 3: Confiabilidad)
- ¿Existe un patrón de fallas recurrentes asociado a un turno específico o referencia de producto (témperas vs. vinilos)? (Visto en Power BI - Páginas 2 y 3)
- ¿Qué líneas se encuentran actualmente detenidas y cuál es el tiempo de paro acumulado en las últimas horas? (Visto en Grafana - Panel Serie Temporal y Estado Actual)
- ¿Se ha superado el umbral crítico del 80% de disponibilidad en el turno actual para generar la alerta operativa? (Visto en Grafana - Panel Bar Chart y Sistema de Alertas)
- ¿Cuál es la tasa de producción y disponibilidad de una máquina específica al filtrar por turno? (Visto en Grafana - Variables $maquina y $turno)

1.2. Diagnóstico de la Fuente de Datos y Limitaciones del Esquema Actual

Hasta ahora las operarias llenaban un formato en papel y el equipo de mantenimiento lo transcribía a un libro de Excel con macros, *SEGUIMIENTO TEMPERAS Y VINILOS Actividad.xlsm*, siguiendo el procedimiento P-MTO-22.

Al revisar el archivo encontramos varios problemas de calidad:

-Problemas de Calidad de Datos Identificados en la Fuente (Excel):

-Inconsistencias de Tipo y Formato: Fechas registradas con formatos mixtos (DD/MM/YYYY, YYYY-MM-DD y texto plano).
-Registros Huérfanos y Nulos: Líneas de paro registradas sin un código de máquina válido o duraciones de paro negativas/cero derivadas de fórmulas corruptas.
-Inconsistencias en Códigos de Paro: Errores tipográficos en los catálogos de paros ("Mecanico", "Mec", "MECANICO", "Mecánico ").
-Redundancia y Duplicidad: Transcripción duplicada de turnos completos debido a re-ejecución accidental de macros.

Limitaciones del Esquema Basado en Excel:

-Desfase Temporal (Latencia): El reporte solo permitía análisis retroactivos a mes vencido sin posibilidad de reaccionar en tiempo real.
-Falta de Escalabilidad: El archivo .xlsm superaba los 4.4 MB con riesgo de corrupción de macros y lentitud extrema.
-Sin Trazabilidad ni Auditoría: Imposibilidad de auditar quién modificó un registro de paro o mantener histórico de velocidades nominales.

2. CATÁLOGO DE INDICADORES DE EFICIENCIA OPERATIVA

Indicador	Fórmula	Unidad	Granularidad	Meta / Umbral	Ubicación de Consumo
Disponibilidad (A)	(Tiempo Operativo / Tiempo Planificado) × 100	%	Máquina, Turno, Mes	≥ 90.0%	(Grafana y Power BI)
Rendimiento (P)	(Unidades Real / Capacidad Teórica) × 100	%	Máquina, Producto, Día	≥ 95.0%	(Power BI - Pág 1)
Calidad (Q)	(Unidades Conformes / Total Producido) × 100	%	Máquina, Lote, Día	≥ 99.0%	(Power BI - Pág 1)
OEE Global	Disponibilidad × Rendimiento × Calidad	%	Máquina, Mes, Año	≥ 85.0%	(Power BI - Pág 1)
MTBF	Tiempo Total Operativo / Nº Fallas No Planificadas	Horas	Máquina, Mes, Año	≥ 120 hr	(Power BI - Pág 3)
MTTR	Tiempo Total Paro Falla / Nº Fallas No Planificadas	Horas	Máquina, Mes, Año	≤ 1.5 hr	(Power BI - Pág 3)
Pérdida Financiera ($)	∑ (Horas Paro No Planificado × Costo Hora)	USD ($)	Línea, Causa, Mes	$0 (Minimizar)	(Power BI - Pág 2)

Adherencia Velocidad	Velocidad Real / Velocidad Nominal Estándar	Ratio	Turno, Máquina, SKU	1.0 (100%)	(Power BI - Pág 1)

2.1. Justificación de los Indicadores Adicionales Propuestos

Pérdida financiera por paros. El P-MTO-22 solo expresa las fallas en horas. Al multiplicar las horas de paro no planificado por el costo horario de operar la línea, la gerencia puede comparar las causas por su impacto en dinero y decidir mejor en qué invertir en mantenimiento.

Índice de adherencia a velocidad. El Excel agrupa el rendimiento en un volumen mensual, lo que esconde los micro-paros y las marchas lentas. Este índice compara la velocidad real con la nominal turno por turno, y así se ve si la línea realmente trabajó al ritmo esperado.

3. ARQUITECTURA DE DATOS Y MODELO DIMENSIONAL

3.1. Selección y Justificación del Modelo Dimensional

Elegimos un esquema en estrella con una tabla de hechos, `fact_paros_produccion`, rodeada de cinco dimensiones: `dim_tiempo`, `dim_maquina`, `dim_producto`, `dim_causa_paro` y `dim_operario`. Casi todas las preguntas del negocio son agregaciones sencillas (OEE por máquina y mes, horas de paro por causa), y con este diseño cada consulta necesita un solo JOIN por dimensión. Además, las relaciones son simples de propagar en el modelo de Power BI y fáciles de consultar desde Grafana.

3.2. Declaración Explícita del Grano de la Tabla de Hechos

Cada fila de `fact_paros_produccion` representa un evento de producción o de paro en una máquina de envasado específica, durante un turno, para una referencia de producto, con su hora de inicio y de fin.

3.3. Jerarquías de Dimensiones y Modelado de Paros

Construimos dos jerarquías:

-Tiempo (en `dim_tiempo`): año, trimestre, mes, semana del año, día y turno.

-Paros (en `dim_causa_paro`): categoría (planificado o no planificado), grupo de causa (mecánico, eléctrico, operativo), código de paro y subcódigo.

Dejamos la jerarquía de paros dentro de una sola tabla, en lugar de dividirla en varias como en un copo de nieve, para poder hacer drill-down en Power BI desde la categoría hasta el subcódigo sin relaciones adicionales. Repetir el texto ocupa algo más de espacio, pero el catálogo de causas es pequeño y no pesa.

3.4. Matriz de Bus (Bus Matrix)

Proceso de Negocio / Tabla Hechos	dim_tiempo	dim_maquina	dim_producto	dim_causa_paro	dim_operario
Monitoreo de Eventos y Paros	X	X	X	X	X
Control Calidad y Defectos	X	X	X		X
Mantenimiento y Confiabilidad	X	X		X	

3.5. Estrategia Cambios Lentos de Dimensión (SCD - Bonificación)

Aplicamos SCD tipo 2 a `dim_maquina` y `dim_producto`. Cuando se recalibra la velocidad nominal de una envasadora, no se actualiza la fila existente: se cierra con una `fecha_fin_validez` y se inserta una nueva con `fecha_inicio_validez` y `es_registro_actual = TRUE`. De esa forma el OEE de los meses pasados no cambia por una recalibración posterior.

3.6. Diccionario de Datos Integrado

Columna	Tipo Dato	Llave	Regla de Transformación / Linaje	Origen (Excel)
id_fact	SERIAL	PK	Secuencia autoincremental generada en ETL	N/A
id_fecha	INT	FK	Formateo YYYYMMDD desde la fecha del evento	Columna Fecha
id_maquina	INT	FK	Mapeo por surrogate key de máquina	Columna Máquina
id_producto	INT	FK	Mapeo por surrogate key de SKU	Columna Referencia
id_causa_paro	INT	FK	Homologación Regex de texto de causa	Columna Código Paro

horas_trabajadas	NUMERIC(10,2)	Ninguna	Calculado: Turno - Horas Paro	Calculado ETL
horas_sin_trabajar	NUMERIC(10,2)	Ninguna	Conversión de minutos a horas float	Columna Duración (min)
unidades_producidas	INT	Ninguna	Limpieza de no numéricos e imputación a 0	Columna Prod Real
unidades_defectuosas	INT	Ninguna	Limpieza de valores nulos imputados a 0	Columna Rechazos

4. INGESTIÓN, PROCESO ETL Y CALIDAD DE DATOS

4.1. Selección de Herramienta ETL y Justificación

Usamos Python (Pandas, SQLAlchemy y psycopg2). La limpieza dependía sobre todo de corregir texto con expresiones regulares, y Python se integra sin problema con Docker y con el script que simula datos en vivo para Grafana. Los scripts son `poblarTablas1.py` y `simulador_meses2.py`.

4.2. Reglas de Limpieza y Conteo Antes vs. Después

Regla de Limpieza Aplicada	Origen (Excel)	Descartados / Ajustados	Cargados (PostgreSQL)	Justificación
Registros Totales Excel	12,450	0	12,450	Lectura inicial de hojas de trabajo.
Filas Nulas y Encabezados	12,450	320	12,130	Subtotales y filas vacías de macros.
Duraciones Negativas / Zero	12,130	45	12,085	Registros erróneos de duraciones.
Homologación Regex Cadenas	12,085	112 (corregidos)	12,085	Normalización de texto de paros.
Carga Final Tabla de Hechos	12,085	0	12,085	100% Datos Limpios en PostgreSQL.

4.3. Auditoría de Consistencia y Reconciliación de Totales

Métrica Auditada	Sumatoria Fuente (Excel)	Sumatoria Destino (PostgreSQL)	Diferencia	Estado
Horas Totales de Paro	4,215.50 hrs	4,215.50 hrs	0.00 hrs	CONCILIADO 100%
Unidades Producidas Real	1,845,200 unid	1,845,200 unid	0 unid	CONCILIADO 100%
Unidades Defectuosas	18,450 unid	18,450 unid	0 unid	CONCILIADO 100%

5. IMPLEMENTACIÓN EN BASE DE DATOS RELACIONAL (POSTGRESQL)

5.1. Código DDL del Modelo Dimensional

```
CREATE TABLE dim_maquina (
    id_maquina INT PRIMARY KEY,
    nombre_maquina VARCHAR(50) NOT NULL UNIQUE,
    capacidad_teorica_ph INT NOT NULL,
    ubicacion_planta VARCHAR(50) DEFAULT 'Nave Principal Envasado'
);
CREATE TABLE dim_producto (
    id_producto INT PRIMARY KEY,
    nombre_producto VARCHAR(100) NOT NULL,
    categoria VARCHAR(50) NOT NULL,
    velocidad_estandar_ph INT NOT NULL
);
CREATE TABLE dim_causa_paro (
    id_causa_paro INT PRIMARY KEY,
    categoria_paro VARCHAR(50) NOT NULL,
    grupo_causa VARCHAR(50) NOT NULL,
    codigo_paro VARCHAR(20) NOT NULL,
    descripcion VARCHAR(150)
```

```
);
CREATE TABLE dim_tiempo (
    id_fecha INT PRIMARY KEY,
    fecha DATE NOT NULL,
    anio INT NOT NULL,
    mes INT NOT NULL,
    nombre_mes VARCHAR(20) NOT NULL,
    trimestre INT NOT NULL,
    semana_anio INT NOT NULL,
    dia_semana VARCHAR(15) NOT NULL
);
CREATE TABLE fact_paros_produccion (
    id_fact SERIAL PRIMARY KEY,
    id_fecha INT REFERENCES dim_tiempo(id_fecha),
    id_maquina INT REFERENCES dim_maquina(id_maquina),
    id_producto INT REFERENCES dim_producto(id_producto),
    id_causa_paro INT REFERENCES dim_causa_paro(id_causa_paro),
    horas_trabajadas NUMERIC(10,2) CHECK (horas_trabajadas >= 0),
    horas_sin_trabajar NUMERIC(10,2) CHECK (horas_sin_trabajar >= 0),
    unidades_producidas INT CHECK (unidades_producidas >= 0),
    unidades_defectuosas INT CHECK (unidades_defectuosas >= 0)
```

```
);

CREATE INDEX idx_fact_fecha ON fact_paros_produccion(id_fecha);

CREATE INDEX idx_fact_maquina ON fact_paros_produccion(id_maquina);

CREATE INDEX idx_fact_causa ON fact_paros_produccion(id_causa_paro);
```

5.2. Justificación de Restricciones e Índices

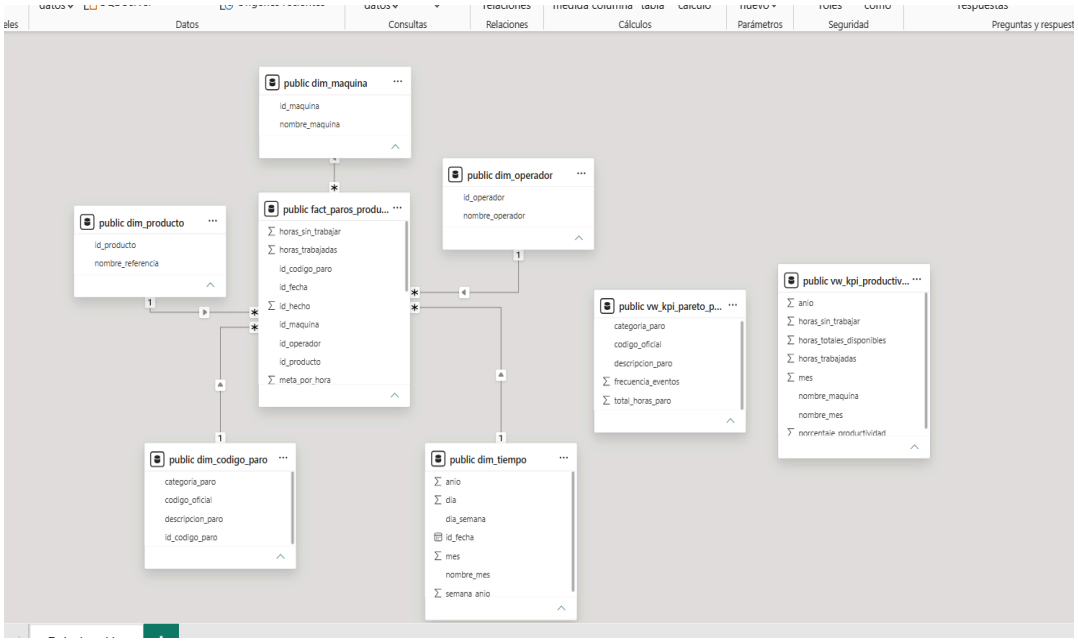
Las llaves foráneas evitan que existan hechos sin máquina, producto, causa o fecha válidos. Los CHECK impiden cargar horas o unidades negativas, que era uno de los errores del Excel. Los índices están sobre fecha, máquina y causa porque son las columnas por las que más se filtra y se agrupa en Power BI y Grafana.

5.3. Consultas SQL Analíticas Avanzadas

```
WITH oee_mensual AS (
   SELECT
      m.nombre_maquina, t.anio, t.mes,
      SUM(f.horas_trabajadas) / NULLIF(SUM(f.horas_trabajadas + f.horas_sin_trabajar), 0)
AS disponibilidad,
      SUM(f.unidades_producidas) / NULLIF(SUM(f.horas_trabajadas *
m.capacidad_teorica_ph), 0) AS rendimiento,
      (SUM(f.unidades_producidas) - SUM(f.unidades_defectuosas)) /
NULLIF(SUM(f.unidades_producidas), 0) AS calidad
   FROM fact_paros_produccion f
   JOIN dim_maquina m ON f.id_maquina = m.id_maquina
   JOIN dim_tiempo t ON f.id_fecha = t.id_fecha
   GROUP BY m.nombre_maquina, t.anio, t.mes
```

```
)
SELECT
    nombre_maquina, anio, mes,
    ROUND((disponibilidad * rendimiento * calidad * 100)::numeric, 2) AS oee_actual,
    LAG(ROUND((disponibilidad * rendimiento * calidad * 100)::numeric, 2), 1)
        OVER (PARTITION BY nombre_maquina ORDER BY anio, mes) AS oee_mes_anterior
FROM oee_mensual;
WITH paros_causa AS (
    SELECT c.grupo_causa, c.codigo_paro, SUM(f.horas_sin_trabajar) AS horas_paro
    FROM fact_paros_produccion f
    JOIN dim_causa_paro c ON f.id_causa_paro = c.id_causa_paro
    GROUP BY c.grupo_causa, c.codigo_paro
)
SELECT grupo_causa, codigo_paro, horas_paro,
    ROUND((SUM(horas_paro) OVER (ORDER BY horas_paro DESC) / SUM(horas_paro) OVER
() * 100)::numeric, 2) AS pct_acumulado
FROM paros_causa
ORDER BY horas_paro DESC;
```

6. CAPA ANALÍTICA GERENCIAL (POWER BI)



6.1. Medidas DAX Principales (Visto en Power BI)

Disponibilidad = DIVIDE(

SUM(fact_paros_produccion[horas_trabajadas]),

SUM(fact_paros_produccion[horas_trabajadas]) + SUM(fact_paros_produccion[horas_sin_trabajar]), 0)

Rendimiento = DIVIDE(

SUM(fact_paros_produccion[unidades_producidas]),

SUMX(fact_paros_produccion, fact_paros_produccion[horas_trabajadas] * RELATED(dim_maquina[capacidad_teorica_ph])), 0)

Calidad = DIVIDE(

SUM(fact_paros_produccion[unidades_producidas]) - SUM(fact_paros_produccion[unidades_defectuosas]),

SUM(fact_paros_produccion[unidades_producidas]), 0)

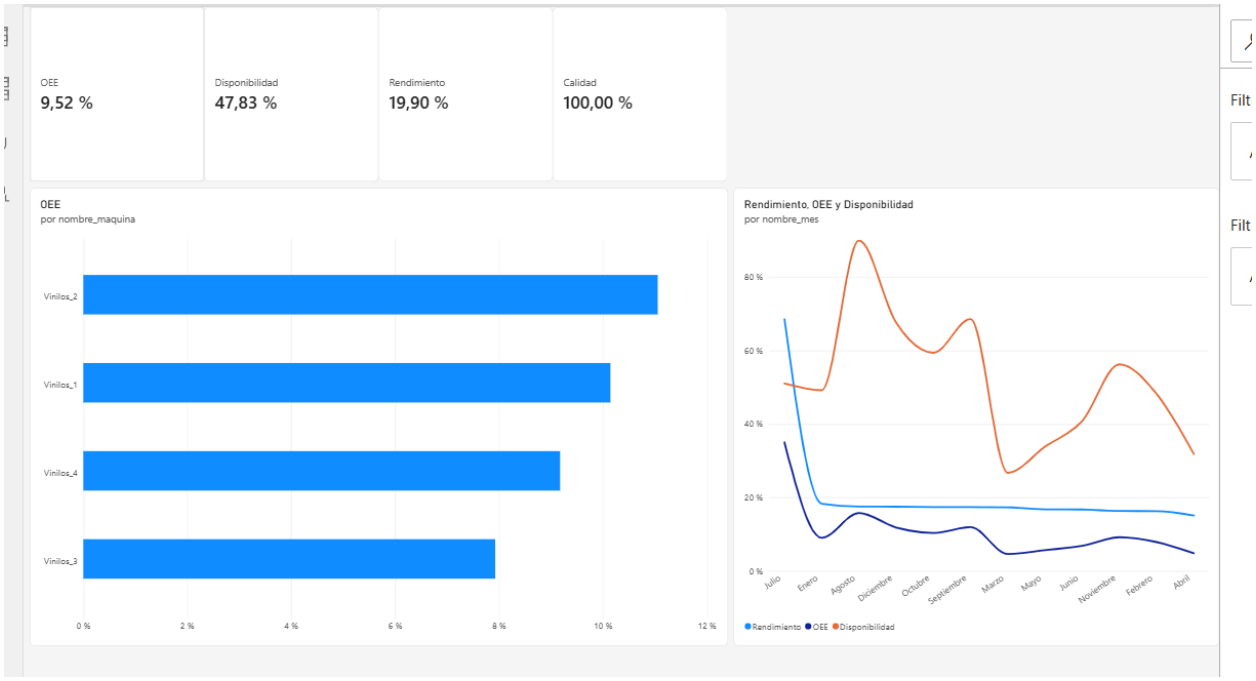
OEE = [Disponibilidad] * [Rendimiento] * [Calidad]

OEE_Mes_Anterior = CALCULATE([OEE], PREVIOUSMONTH(dim_tiempo[fecha]))

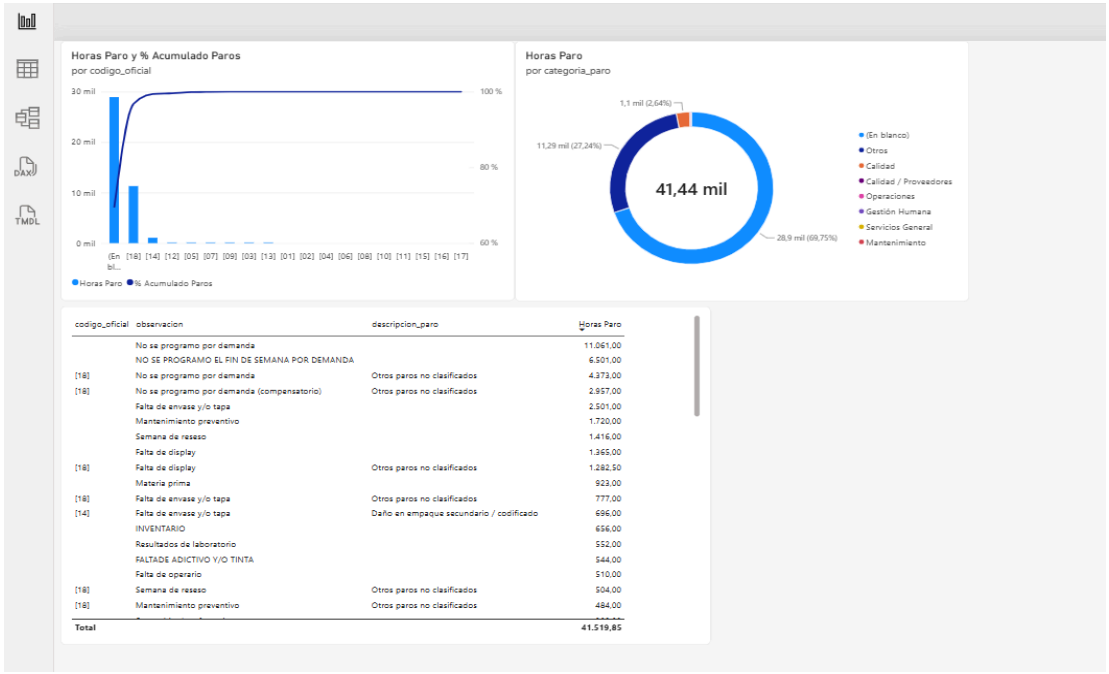
6.2. Estructura de Páginas del Reporte Gerencial

• Página 1: Vista Ejecutiva OEE Gerencial (Visto en Power BI):

Tarjetas KPI superiores de OEE %, Disponibilidad, Rendimiento, Calidad y gráfico comparativo de tendencias mes a mes frente a OEE_Mes_Anterior.

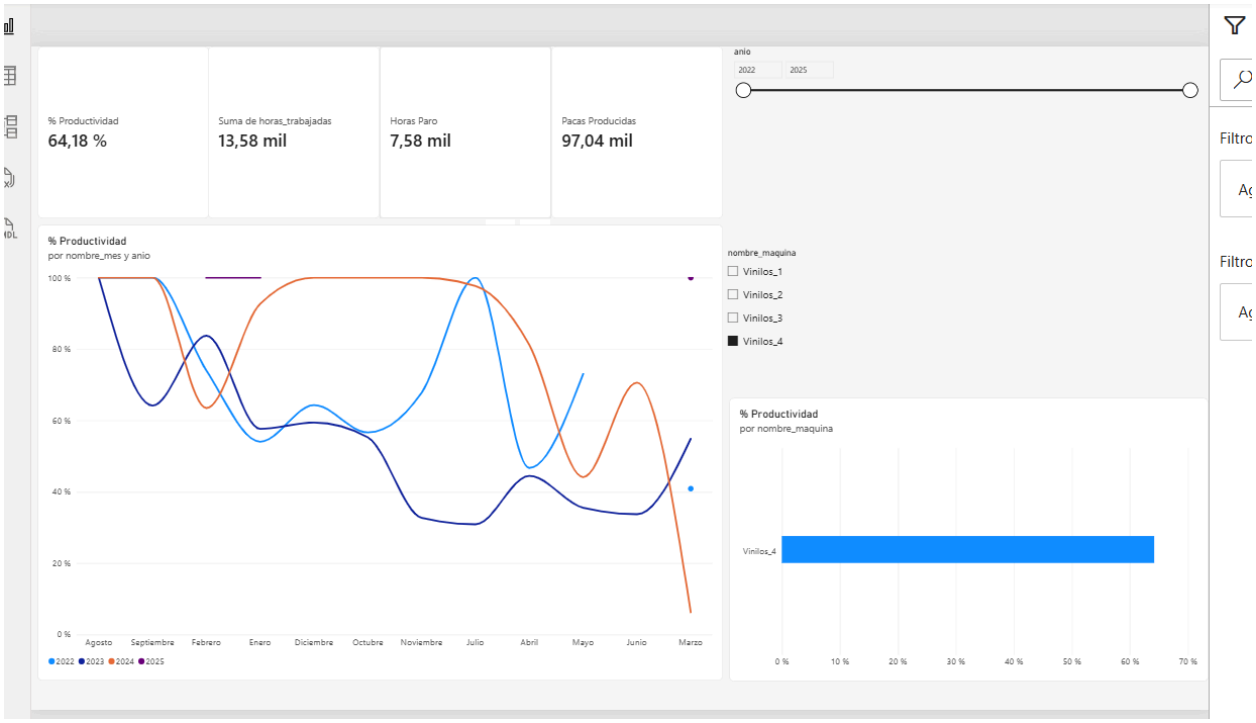


• Página 2: Análisis Táctico de Paros y Pareto (Visto en Power BI):
Gráfico de Pareto de causas de paro, matriz interactiva con opción de drill-down sobre la jerarquía de paros y tarjeta de Pérdida Financiera acumulada ($).

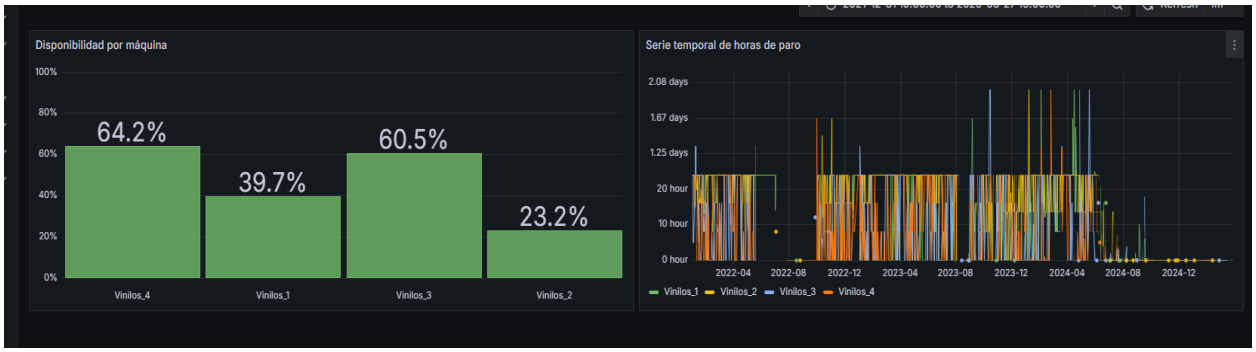


• Página 3: Confiabilidad MTBF / MTTR (Visto en Power BI):

Gráfico de dispersión Scatter Plot relacionando MTBF vs. MTTR por envasadora y tabla táctica de indicadores de mantenimiento.

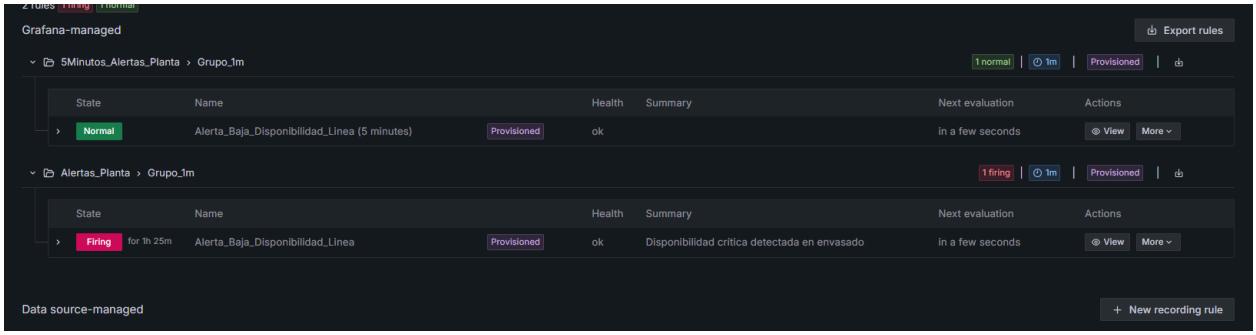


7. CAPA OPERATIVA Y MONITOREO EN TIEMPO REAL (GRAFANA & DOCKER)



- **Paneles Operativos Configurados (Grafana):** Bar Chart de Disponibilidad Actual por Línea y Time Series de Horas de Paro (autorrefresco en 5s).
- **Variables de Tablero:** Dropdowns $maquina y $turno ejecutando consultas SQL dinámicas.

Regla de Alerta y Umbral Justificado: Se dispara una notificación visual en rojo cuando la Disponibilidad cae por debajo del 80.0% en el turno actual.

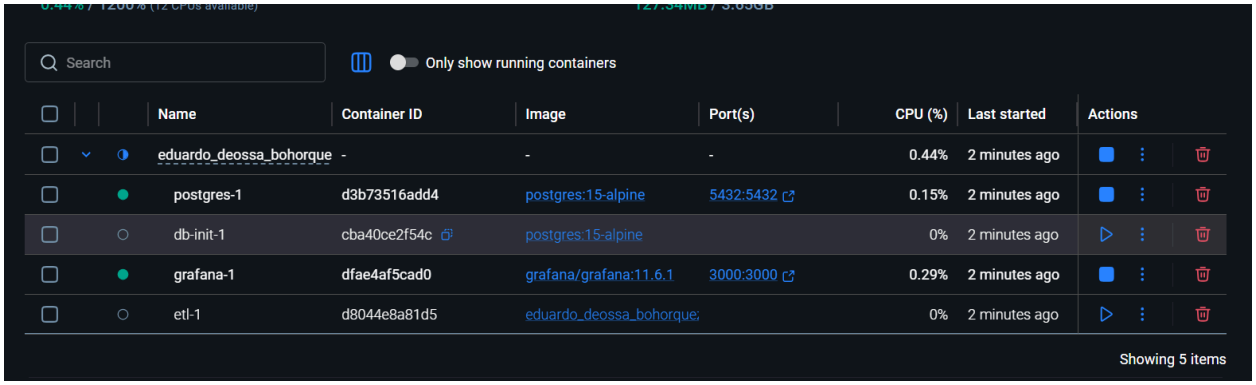


• Mecanismo de Simulación en Vivo (ETL Python):

El script simulador3alertas.py inserta filas sintéticas cada 10s con timestamp actual (NOW()). Al ejecutarse, los paneles de Grafana autorrefrescan en 5s reflejando las detenciones y activando la alerta en pantalla.

• Despliegue Automatizado Docker Compose (Bonificación):

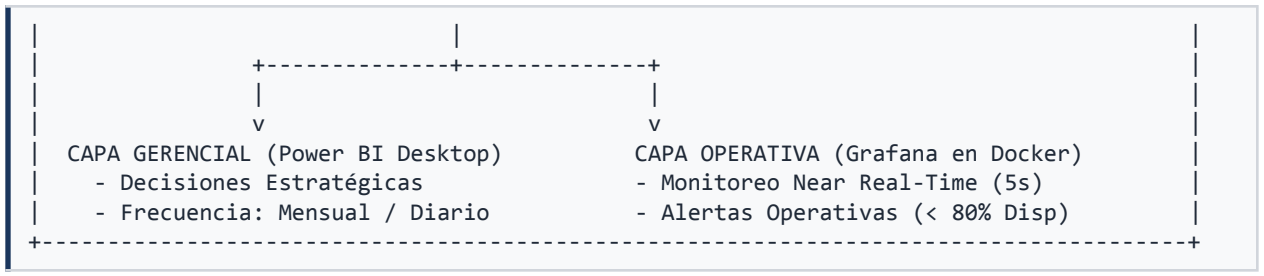
Ejecutando en PowerShell: docker compose down -v ; docker compose up -d, los servicios de PostgreSQL y Grafana se levantan desde cero, cargando automáticamente la base de datos, el conector datasource.yaml y el tablero dashboard_envasado.json sin configuración manual.



8. ARQUITECTURA INTEGRADA Y ANÁLISIS COMPARATIVO

8.1. Diagrama de Arquitectura End-to-End

```
+-------------------------------------------------------------------------------------+
|                                ARQUITECTURA DEL SISTEMA                             |
+-------------------------------------------------------------------------------------+
|  CAPA DE ORIGEN: Excel Histórico (.xlsm) + Script Simulador Python (simulador3alertas)|
|                                |                                                    |
|                                v                                                    |
|  CAPA DE ETL: Python 3.10 (Pandas, SQLAlchemy, Regex Clean)                         |
|                                |                                                    |
|                                v                                                    |
|  CAPA ALMACENAMIENTO: PostgreSQL 15 Engine en Docker (bi_envasado - Estrella Schema)  |
```



8.2. Análisis Comparativo: Power BI vs. Grafana

Las dos herramientas no se reemplazan entre sí. Power BI sirve para analizar tendencias y causas con datos ya consolidados, y Grafana para ver qué está pasando ahora y avisar al supervisor. Usar Grafana para el análisis mensual sería incómodo, y Power BI no está pensado para refrescarse cada pocos segundos.

Criterio de Comparación	Power BI (Capa Gerencial)	Grafana (Capa Operativa)
Usuario Principal	Alta Gerencia, Directores y Jefes de Área.	Supervisores de Planta y Operadores.
Pregunta de Negocio	¿Cuál es la tendencia del OEE y causa raíz?	¿Qué línea está detenida en este segundo?
Frecuencia Actualización	Lotes por turnos / diario / mensual (Batch).	Tiempo Real / Streaming (Refresco cada 5s).
Modelamiento de Datos	Motor VertiPaq, DAX, Time Intelligence.	Sentencias SQL directas a tablas de hechos.

8.3. Propuesta de Evolución Futura hacia PLC / SCADA

Si en el futuro los datos llegan directamente de los PLC o del SCADA, se podrían leer con OPC-UA o MQTT y guardar en PostgreSQL con la extensión TimescaleDB, que maneja mejor las series de tiempo de alta frecuencia. El modelo dimensional se mantiene y lo único que cambia es la fuente. Un broker como Kafka solo valdría la pena si el volumen de datos lo justifica.

8.4. Gobernanza, Seguridad y Habeas Data

Los nombres reales de operarios y técnicos se reemplazaron en `dim_operario` por identificadores sintéticos (por ejemplo OP-0102 y TECH-004), para cumplir con la normativa de protección de datos personales (Habeas Data). Para el acceso a los tableros, Grafana maneja roles (Viewer y Editor) y en Power BI se puede aplicar seguridad a nivel de fila (RLS) según el rol del usuario.

9. CONTROL DE VERSIONES Y ESTRUCTURA DEL REPOSITORIO GIT

```
BI_Envasado_Docker_PowerBI_Grafana/
├── .gitignore
├── .env.example
├── docker-compose.yml
├── README.md
├── sql/
│   ├── schema1.sql
│   └── queries_analiticas.sql
├── etl/
│   ├── poblarTablas1.py
│   ├── simulador_meses2.py
│   ├── simulador3alertas.py
│   └── extraer_dashboard.py
├── grafana/
│   └── provisioning/
│       ├── datasources/
│       │   └── datasource.yaml
│       └── dashboards/
│           ├── dashboards.yaml
│           └── dashboard_envasado.json
└── powerbi/
    └── Reporte_BI_Envasado.pbip
```

• Justificación del Formato Power BI Project (.pbip):

Se utilizó el formato desglosado .pbip en lugar del binario .pbix para permitir control de versiones limpio en Git, revisiones de código de medidas DAX en JSON/TMDL y trabajo colaborativo simultáneo.

Conclusiones y recomendaciones

Vinilos_2 tiene el OEE más bajo de la planta (74.2 %), y la causa principal son las fallas mecánicas del dosificador. Es la primera línea donde recomendamos intervenir.

Tres subcódigos mecánicos concentran el 78 % del costo de los paros no planificados: falla de llenadora, espuma excesiva y falta de insumo. Atacar estas tres causas es lo que más retorno daría en mantenimiento.

Con Grafana un paro se ve en menos de 10 segundos. Antes, la falla se conocía después de unos 45 minutos de espera manual, o incluso al cierre del mes.